

商用航空发动机情报系统测试方案

本方案用于商用航空发动机多智能体情报系统的功能测试及线上演示准备，验证资料检索、协同研究、报告生成、来源追溯和指标测评流程。测试人员按本方案执行并保存证据，依据实际结果判定，不预填“通过”。

1 测试环境 载荷与条件

(1) 使用已部署本项目的 Windows 计算机，记录操作系统、处理器、内存、浏览器及程序版本。确认模型服务、检索服务和本地资料索引可用；模型名称及接口配置与本次记录一致。

(2) 保持网络稳定，确认能够访问模型接口、搜索服务及部分公开来源网站。检查项目输出目录可写，准备足够磁盘空间；共享屏幕时避免展示密钥及敏感资料。

(3) 准备与发动机研究主题相关的论文、专利和用户资料，登记文件名、来源、关键内容及所在页码。另准备一份可正常解析的 PDF 或 DOCX 副本用于上传，避免重复污染正式资料库。

(4) 主流程采用单任务运行。建议选择“技术动态研报”“短报告 (DeepSeek Flash)”，检索范围包含论文、专利、用户资料与公开网页，精读/抓取上限设为 5；该上限按查询执行，不代表整份报告最多使用 5 个网页。记录界面实际参数。

(5) 测试期间保持配置稳定，不同时运行其他研究任务。网络异常、接口限流、索引未完成等情况单独记录，不归入正常完成样本；功能补测和正式验收均保留原失败记录。

(6) 线上展示前完成一次全流程预演，准备已检查的报告及来源原文作为备用材料，并明确标注“预生成样例”。正式准确率验收另行组织，不以一次演示代替多轮测试。

2 测试方法

采用界面操作、运行日志检查、报告与原文对照相结合的方法。先验证主流程，再检查来源质量和异常处理，最后整理测试结果。

一 测试准备

1、启动项目根目录的 `start_system.bat`，待后台启动完成后，在浏览器访问 `http://127.0.0.1:8000`。确认任务配置、资料列表及报告预览区域正常显示。

2、在资料库中查询准备好的文件，打开原文核对内容；完成上传与索引检查后，保存任务配置截图，登记测试开始时间、资料版本及网络状态。

二 测试运行

1、输入固定测试任务，点击“启动情报任务”，记录任务编号。通过“运行日志”和“状态”观察需求规划、检索研究、写作与导出等实际阶段，不重复提交。

2、报告完成后，依次检查正文结构、网页来源处理明细、参考文献及本地来源映射。将正文关键结论与保存的原文逐项对照，检查型号、日期、数量、单位及事件状态。

3、下载主报告及指标附件，复核文件内容和测评明细。对未通过项记录触发条件、日志、截图及预期差异，修复后按原步骤复测。

三 数据记录与结束

1、保存任务配置、运行日志、来源记录 JSON、报告和指标附件，以任务编号关联。保留网页抓取时间、原始地址及本地原文，便于后续复查。

2、确认文件已保存且任务结束后关闭页面；需要停止服务时，在本次启动的后台窗口中按 Ctrl+C。任务尚在运行时，不通过关闭后台结束演示。

3 测试步骤与展示内容

下列步骤按顺序执行。每项填写“通过、未通过、未完成、未执行”，同时注明证据位置。一次操作可用于多个检查项，但各项结论应分别记录。

一 系统启动与资料准备

(1) 系统启动。执行第 2 节的启动步骤，刷新首页并打开资料列表，确认页面与后台连接正常。预期：主要区域正常加载，已有资料可查询，无阻断性报错。展示：首页、任务配置和本地资料库。

(2) 资料上传。在“资料上传”中选择测试文件及目标资料库，点击“上传并加入检索范围”，等待索引处理结束，再按文件名或关键字查询。预期：上传状态可见，文件可检索，原文与上传内容一致。展示：上传结果、检索条目和原文关键页。

二 任务配置与协同研究

(3) 配置主任务。按第 1 节填写报告类型、长短及检索范围，领域需求模型使用自动匹配；如使用任务模板，记录模板名称和版本。将下述内容完整填入“情报任务描述”。

跟踪普惠 GTF 发动机技术问题与市场影响，重点关注 PW1000G 系列粉末金属污染、受影响部件、适航响应、维修保养及交付影响。梳理测试日前 12 个月的进展；早期事件作为背景并标注日期。区分具体型号、计划与实际状态，结合本地资料和公开网页形成中文报告，为关键事实保留可追溯引用。

预期：配置与记录一致，需求覆盖技术问题、适航、维修和市场影响。展示：任务描述、参数和资料范围，说明本次研究边界。

(4) 启动并观察运行。点击“启动情报任务”，记录任务编号和提交时间；打开“状态”，观察日志及检索覆盖可视化。预期：任务按阶段推进，检索资料与主题相关，异常可定位；页面显示的覆盖数量不被解释为准确率。展示：研究阶段、检索范围和当前进度。

三 网页来源与引用核查

(5) 检查网页处理过程。打开“网页来源处理明细”，分别查看已引用、未引用、抓取失败及排除项；下载“来源记录 JSON”。对照查询词、链接、抓取状态和排除原因，区分搜索命中、原文抓取、写作选用和正文引用各阶段。

预期：各阶段记录能够对应，数量差异有可查原因。重复网址按同一来源理解，不以搜索命中数代替有效参考文献数；与航空发动机无关的同名 GTF 内容不进入有效证据。展示：一个已引用来源及一个未引用或失败来源的处理记录。

（6）检查链接及时效。逐一点击正文实际引用的公开链接，记录正常访问、跳转、失效或需登录等状态；对照网页标题、发布日期与保存的正文。将近 12 个月进展和早期背景分开核查，日期不明的来源不得直接标为最新消息。

预期：链接指向对应文章，正文确有可用内容；旧资料用于有日期的背景叙述。失效链接、验证码页、摘要代替全文等问题如实列出。网页打不开时，保存原文可用于内容复核，但不能据此判定实时链接可访问。展示：网页、日期及报告对应段落。

（7）检查正文引用与参考文献。逐段检查型号参数、事件日期、适航要求及市场数据等关键事实，确认附近有有效引用，编号能映射到正确来源。相关事实可在同一段内共用引用，但原文应支持该段的全部相关断言；图表另核查来源说明。

预期：正文引用与文后目录双向对应，不出现空链接、错配编号、虚构条目或仅图表有来源而主体无引用的情况。缺证据的结论应提示复核或明确保留不确定性，不为凑文献数量添加无依据引用。展示：正文段落、引用编号和文后条目。

(8) 检查本地与网页原文。演示时至少选择 2 处本地引用和 3 处网页引用，分别打开原文核对；样本不足时全查并注明数量。正式验收按全部测评项检查，不以演示抽样代替。

预期：本地引用能定位到具体文件及原文位置，网页引用能定位到对应原文内容；型号、数字、单位、日期与事件状态一致。正文未出现的候选实体不纳入正文实体核验。展示：一处本地原文对照和一处网页原文对照，说明“有链接”与“原文支持结论”的区别。

四 报告与测评结果检查

(9) 检查报告及导出。浏览全文，确认内容覆盖需求，章节衔接正常，无写作失败提示残留。分别下载 Markdown、Word 及 PDF 并打开，检查标题、段落、图表、引用编号和参考文献；从历史记录进入同一任务，核对文件归属。

预期：下载文件可读，主要内容一致，无乱码、明显截断、图表缺失及串用其他任务结果。展示：报告预览、Word 或 PDF 成稿、历史任务入口。

(10) 检查指标附件。打开“指标测评”，核对任务编号、生成耗时、实体及公开来源核验明细。选择正确、错误或无法核实的实际样本，回到正文和原文检查判定依据；未出现某类样本时注明，不人为构造结果。

预期：指标样本来自本次报告，核验状态与证据一致。无法核实项保留在统计范围并列明原因；没有有效样本或核

验尚未完成时，不宣称达标。展示：指标总览、一个具体核验项及其证据。

五 异常处理与验收判定

（11）异常补测。在独立测试任务中提交空需求，检查是否拒绝启动并提示；对实际发生或在隔离测试环境中模拟的抓取失败、模型超时、写作失败、导出失败，检查错误提示和记录。不要在现场演示中修改正式接口配置制造故障。

预期：失败环节可定位，未生成完整正文的任务不得被判为成功，失败内容不得作为有效来源。恢复条件后重新运行，保留新旧任务编号。若某异常未能触发，应记“未执行”，不能以正常运行推断异常处理通过。

（12）正式指标验收。按项目当前测评目标，至少完成 10 轮测试，每轮报告生成时间不超过 20 分钟、核心技术实体抽取准确率不低于 90%、公开信息溯源链接准确率不低于 98%。每轮须有有效实体及公开来源样本；仅本地资料的功能测试不替代公开来源准确率验收。

生成时间采用系统记录的研究启动至主报告导出完成口径；浏览器下载及指标附件另行记录。准确率以正确项数除以全部待核验项数计算，无法核实项不从分母剔除。公开来源还需验证其是否支持正文断言，不能只检查链接是否打开。

各轮固定模型、抓取上限及资料范围，保存独立任务编号；可选 GTF 技术问题、适航响应、维修保障、交付影响和竞争型号跟踪五类任务，每类执行两轮。自动裁判结果由测

试人员结合原文复核；每轮分别判定，不用平均值掩盖单轮未达标。

整体功能通过需主流程完整且无阻断性缺陷；指标通过需满足上述各轮要求。未执行、未完成或证据不足的项目均保留待处理状态。该方案规定验收目标，不代表当前版本已经达到目标。

六 线上展示与结果记录

（13）线上展示建议控制在 20 分钟：前 3 分钟介绍任务与资料范围并提交任务；第 3 至 8 分钟展示上传、检索及运行日志；第 8 至 14 分钟展示报告结构及原文对照；第 14 至 18 分钟展示导出文件、来源记录和指标明细；最后 2 分钟说明实际完成项与遗留问题。

报告尚未完成时，明确切换到“预生成样例”讲解，并让现场任务继续运行；样例与现场结果分别标注任务编号。演示前检查屏幕共享、文件打开及来源访问情况，避免临场下载大文件或调整模型配置。

（14）每项记录测试编号、执行时间、任务编号、操作配置、实际结果、结论、截图或文件位置。缺陷另记复现步骤、影响范围、处理人及复测结果。正式验收保留全部轮次，包括失败和补测记录。

测试日期：_____ 测试人员：_____

程序版本：_____ 主任务编号：_____

功能结论：_____ 指标结论：_____

遗留问题及证据位置：_____

复测安排：_____